

TRƯỜNG ĐẠI HỌC CÔNG THƯƠNG TP. HỒ CHÍ MINH
KHOA THƯƠNG MẠI



BÀI BÁO CÁO

HỌC PHẦN: PHÂN TÍCH NGÔN NGỮ TỰ NHIÊN

**ĐỀ TÀI: NHẬN DIỆN Ý ĐỊNH NGƯỜI DÙNG
TRONG CHAT MUA HÀNG**

GVHD: ThS. ĐÌNH MINH HÒA

Lớp: 14DHTMDT02

Nhóm: 16

Thành viên:

1. Trần Tuấn Kiệt_2044230089
2. Võ Thanh Hiền_2044230065
3. Nguyễn Thị Thanh Nhã_2044230151

Tp. Hồ Chí Minh, ngày 20 tháng 05 năm 2026

LỜI CẢM ƠN

Trong quá trình thực hiện đề tài “Nhận diện ý định người dùng trong chat mua hàng”, nhóm đã nhận được rất nhiều sự hỗ trợ và hướng dẫn từ giảng viên cũng như các thành viên trong lớp. Nhóm xin gửi lời cảm ơn chân thành đến Thạc sĩ Đinh Minh Hòa đã tận tình hướng dẫn, hỗ trợ và đưa ra nhiều góp ý quan trọng trong suốt quá trình thực hiện đề tài. Những kiến thức và định hướng từ thầy đã giúp nhóm hoàn thiện bài báo cáo một cách tốt hơn cả về nội dung lẫn phương pháp thực hiện.

Bên cạnh đó, nhóm cũng xin cảm ơn các thành viên trong nhóm đã luôn tích cực trao đổi, tìm hiểu tài liệu và hỗ trợ lẫn nhau trong quá trình xây dựng hệ thống và hoàn thiện báo cáo. Sự phối hợp và tinh thần làm việc nhóm là yếu tố quan trọng giúp đề tài được thực hiện đúng tiến độ.

Cuối cùng, nhóm xin gửi lời cảm ơn đến bạn bè và gia đình đã luôn động viên, hỗ trợ tinh thần trong suốt quá trình học tập và nghiên cứu.

Mặc dù nhóm đã cố gắng hoàn thiện đề tài một cách tốt nhất, tuy nhiên do kiến thức và kinh nghiệm thực tế còn hạn chế nên bài báo cáo khó tránh khỏi những thiếu sót. Nhóm rất mong nhận được những ý kiến đóng góp quý báu từ giảng viên để đề tài được hoàn thiện hơn.

Nhóm xin chân thành cảm ơn!

MỤC LỤC

DANH MỤC HÌNH ẢNH	IV
DANH MỤC BẢNG BIỂU	IV
CHƯƠNG 1: GIỚI THIỆU ĐỀ TÀI.....	1
1.1. Tổng quan bài toán nhận diện ý định	1
1.1.1. Định nghĩa và vị trí trong NLP	1
1.1.2. Các phương pháp tiếp cận chính	2
1.1.3. Đặc thù và thách thức của Tiếng Việt.....	2
1.2. Vai trò của bài toán trong thương mại điện tử	2
1.3. Mục tiêu của đề tài	3
1.4. Phạm vi nghiên cứu	3
1.4.1. Về dữ liệu	3
1.4.2. Về mô hình	3
1.4.3. Về ngôn ngữ	4
1.4.4. Về bài toán	4
CHƯƠNG 2: PHÂN TÍCH DỮ LIỆU	5
2.1. Mô tả dataset	5
2.1.1. Cấu trúc dữ liệu	5
2.1.2. Thống kê tổng quan.....	5
2.2. Các nhóm intent trong dữ liệu.....	6
2.3. Khám phá dữ liệu EDA	9
2.3.1. Phân bố theo nhóm intent	9
2.3.2. Phân tích độ dài câu chat	10
2.3.3. Phân tích biểu đồ phân phối (histogram)	11
2.3.4. Phân tích Word Cloud	12

III

2.3.5. Phân tích đặc điểm ngôn ngữ	12
2.4. Nhận xét về dữ liệu.....	13
2.4.1. Về điểm mạnh.....	13
2.4.2. Về hạn chế và thách thức	13
CHƯƠNG 3: XÂY DỰNG BÀI TOÁN.....	14
3.1. Xác định bài toán.....	14
3.2. Kiến trúc tổng thể của hệ thống.....	14
3.3. Tiền xử lý dữ liệu	15
3.4. Gán nhãn ý định	16
3.5. Tăng cường dữ liệu.....	17
3.6. Thực hiện Easy Data Augmentation (EDA).....	18
3.7. Thực hiện Back Translation	18
3.8. Chia tập dữ liệu huấn luyện và kiểm tra.....	19
3.9. Vector hóa dữ liệu bằng TF-IDF	19
3.10. Huấn luyện các mô hình học máy truyền thống.....	20
3.11. Đánh giá bằng Cross Validation.....	20
3.12. Triển khai mô hình PhoBERT	21
3.13. Kết quả thực nghiệm	22
3.14. So sánh ưu và nhược điểm của các mô hình	22
CHƯƠNG 4: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN.....	24
4.1. Kết luận	24
4.2. Những đóng góp của đề tài.....	25
4.3. Hạn chế của đề tài	25
4.4. Hướng phát triển.....	26
CHƯƠNG 5: TÀI LIỆU THAM KHẢO	28
PHỤ LỤC	29

DANH MỤC HÌNH ẢNH

Hình 2.1. Biểu đồ phân bố dữ liệu theo intent.....12

Hình 2.2. Word Cloud của tập dữ liệu.....12

Hình 2.1. Phân bố dữ liệu theo intent10

Hình 2.2. Biểu đồ phân bố dữ liệu theo intent.....12

Hình 2.3. Word Cloud của tập dữ liệu.....12

Hình 3.1. Pipeline tổng quát của hệ thống.....15

DANH MỤC BẢNG BIỂU

Bảng 3.1. Tổng hợp các chỉ số của các mô hình22

Bảng 3. 2. Ưu nhược điểm của các mô hình23

CHƯƠNG 1: GIỚI THIỆU ĐỀ TÀI

1.1. Tổng quan bài toán nhận diện ý định

Nhận diện ý định (Intent Classification) là một bài toán thuộc lĩnh vực Xử lý ngôn ngữ tự nhiên (Natural Language Processing - NLP), trong đó mục tiêu là xác định mục đích hoặc ý nghĩa chính mà người dùng muốn truyền tải thông qua văn bản. Trong môi trường thương mại điện tử, các phản hồi của khách hàng thường chứa nhiều thông tin liên quan đến chất lượng sản phẩm, dịch vụ giao hàng, giá cả hoặc trải nghiệm mua sắm. Việc tự động nhận diện các ý định này giúp doanh nghiệp nhanh chóng tổng hợp phản hồi, phát hiện vấn đề và nâng cao chất lượng dịch vụ.

Trong đề tài này, dữ liệu đầu vào là các đánh giá bằng tiếng Việt của khách hàng. Hệ thống được xây dựng nhằm phân loại các đánh giá đó vào các nhóm ý định khác nhau như khen chất lượng sản phẩm, phàn nàn chất lượng, khen giao hàng, phàn nàn giao hàng, khen dịch vụ hoặc các đánh giá trung tính.

1.1.1. Định nghĩa và vị trí trong NLP

Nhận diện ý định (Intent Detection hay Intent Recognition) là một bài toán trung tâm trong lĩnh vực Xử lý Ngôn ngữ Tự nhiên (Natural Language Processing - NLP), thuộc nhánh hiểu ngôn ngữ tự nhiên (Natural Language Understanding - NLU). Mục tiêu của bài toán là xác định mục đích hoặc nhu cầu mà người dùng muốn truyền đạt thông qua một câu văn bản đầu vào, và gán câu đó vào một trong các nhóm ý định (intent) được định nghĩa trước.

Về mặt hình thức, đây là bài toán phân loại văn bản đa lớp (*multi-class text classification*). Với một câu văn bản đầu vào x , mô hình cần học hàm ánh xạ:

$$f: x \rightarrow y \quad (1)$$

Trong đó:

x : Câu đầu vào.

f : Hàm phân loại.

Y : Tập nhãn.

y : Nhãn đầu ra hay là một nhãn ý định thuộc tập nhãn hữu hạn.

$$Y = \{y_1, y_2, \dots, y_n\}$$

Lấy ví dụ với câu “giá sản phẩm này bao nhiêu?” được gán nhãn `hoi_gia`, câu “shop giao sai hàng rồi shop ơi” được gán nhãn `khieu_nai`, hay câu “đặt giúp em màu trắng nha” được gán nhãn `dat_hang`.

Nhận diện ý định là thành phần không thể thiếu trong các hệ thống hội thoại tự động (dialogue systems), trợ lý ảo (virtual assistant) và chatbot thương mại. Khi hệ thống biết được ý định của người dùng, nó có thể định tuyến yêu cầu đến module xử lý phù hợp, tra cứu cơ sở dữ liệu, hoặc sinh ra phản hồi có nội dung đúng nhu cầu - thay vì chỉ phản hồi theo mẫu cứng nhắc.

1.1.2. Các phương pháp tiếp cận chính

Có hai hướng tiếp cận chính được sử dụng trong đề tài.

Hướng tiếp cận thứ nhất là học máy truyền thống. Văn bản được chuyển đổi thành vector số bằng phương pháp TF-IDF với số lượng đặc trưng tối đa là 5.000 và sử dụng unigram kết hợp bigram. Sau đó dữ liệu được huấn luyện bằng các mô hình Naive Bayes, Logistic Regression và Support Vector Machine (SVM).

Hướng tiếp cận thứ hai là học sâu sử dụng mô hình ngôn ngữ tiền huấn luyện PhoBERT. Đây là mô hình Transformer được VinAI phát triển dành riêng cho tiếng Việt. PhoBERT có khả năng học ngữ nghĩa và ngữ cảnh tốt hơn các phương pháp học máy truyền thống, từ đó nâng cao độ chính xác phân loại.

1.1.3. Đặc thù và thách thức của Tiếng Việt

Tiếng Việt là ngôn ngữ đơn âm tiết nhưng từ có thể được cấu thành bởi nhiều tiếng. Điều này làm cho quá trình tách từ trở nên phức tạp hơn so với tiếng Anh. Ngoài ra, dữ liệu phản hồi của khách hàng thường chứa từ viết tắt, từ địa phương, lỗi chính tả hoặc biểu cảm cảm xúc không theo quy chuẩn ngôn ngữ.

Một khó khăn khác là sự mất cân bằng dữ liệu giữa các nhóm ý định. Trong tập dữ liệu gốc, nhóm `khen_chat_luong` có 1.835 mẫu trong khi nhóm `phan_nhan_dich_vu` chỉ có 6 mẫu. Điều này gây ảnh hưởng đáng kể đến khả năng học của mô hình và đòi hỏi phải áp dụng các kỹ thuật tăng cường dữ liệu.

1.2. Vai trò của bài toán trong thương mại điện tử

Trong các hệ thống thương mại điện tử hiện đại, số lượng đánh giá sản phẩm và phản hồi khách hàng tăng lên liên tục. Việc đọc và phân loại thủ công toàn bộ dữ liệu là

không khả thi. Bài toán nhận diện ý định giúp doanh nghiệp tự động phân loại các phản hồi theo nội dung cụ thể để phục vụ hoạt động phân tích khách hàng.

Khi khách hàng phản nản về giao hàng hoặc chất lượng sản phẩm, hệ thống có thể nhanh chóng phát hiện và chuyển thông tin tới bộ phận liên quan. Ngược lại, các phản hồi tích cực có thể được sử dụng để đánh giá điểm mạnh của sản phẩm hoặc làm dữ liệu tham khảo cho các chiến dịch marketing.

1.3. Mục tiêu của đề tài

Mục tiêu chính của đề tài là xây dựng một hệ thống phân loại ý định cho các phản hồi khách hàng bằng tiếng Việt trong lĩnh vực thương mại điện tử.

Đề tài tập trung vào việc thu thập và xử lý dữ liệu, xây dựng tập dữ liệu có nhãn, thực hiện phân tích khám phá dữ liệu, áp dụng các phương pháp tăng cường dữ liệu, huấn luyện các mô hình học máy truyền thống và mô hình PhoBERT, sau đó đánh giá và so sánh hiệu năng giữa các mô hình.

1.4. Phạm vi nghiên cứu

Để đảm bảo tính tập trung và khả thi trong khuôn khổ của đề tài, phạm vi nghiên cứu được xác định như sau:

1.4.1. Về dữ liệu

Nguồn dữ liệu của đề tài là các phản hồi văn bản của khách hàng liên quan đến sản phẩm và dịch vụ trong môi trường thương mại điện tử `v3_sentences.csv`. Sau khi làm sạch dữ liệu, tập dữ liệu gốc gồm 4.527 mẫu. Sau quá trình tăng cường dữ liệu bằng EDA và Back Translation, số lượng mẫu tăng lên 8.810.

Dữ liệu nghiên cứu là các phản hồi văn bản bằng tiếng Việt được lưu trong tập dữ liệu đầu vào. Sau khi xử lý và loại bỏ nhiễu trong file `XuLyData.ipynb`, dữ liệu được lưu thành tập tin `data_cleaned_with_intent.csv`.

Tiếp theo, dữ liệu được tăng cường trong file `AugmentData.ipynb` và lưu thành tập tin `data_augmented.csv` để phục vụ quá trình huấn luyện mô hình.

1.4.2. Về mô hình

Đề tài giới hạn trong việc so sánh các mô hình: Multinomial Naive Bayes, Logistic Regression (max_iter=1000), Linear SVC, và PhoBERT (vinai/phobert-base). Không nghiên cứu các mô hình khác như XGBoost, CNN, LSTM hay các biến thể BERT khác.

1.4.3. Về ngôn ngữ

Đề tài chỉ tập trung xử lý dữ liệu tiếng Việt. Các kỹ thuật tiền xử lý và mô hình được lựa chọn đều hướng đến việc khai thác đặc điểm ngôn ngữ tiếng Việt.

1.4.4. Về bài toán

Đề tài chỉ nghiên cứu bài toán phân loại ý định đa lớp và không mở rộng sang các bài toán khác như phân tích cảm xúc hoặc nhận dạng thực thể.

CHƯƠNG 2: PHÂN TÍCH DỮ LIỆU

2.1. Mô tả dataset

Bộ dữ liệu được sử dụng trong đề tài là `v3_sentences.csv`, một tập dữ liệu được xây dựng từ các bình luận mua sắm thực tế của khách hàng trên các nền tảng thương mại điện tử phổ biến tại Việt Nam như Shopee và Lazada.

Quá trình xử lý dữ liệu được thực hiện trong file `XuLyData.ipynb`.

Đầu tiên, dữ liệu được tải lên bằng thư viện Pandas và lưu vào DataFrame với cột văn bản gốc là `text`. Sau đó hệ thống tiến hành làm sạch dữ liệu bằng hàm `clean_text()`.

Hàm này thực hiện chuẩn hóa khoảng trắng, loại bỏ các ký tự không cần thiết và giữ lại các ký tự tiếng Việt. Tiếp theo, hàm `is_noise()` được sử dụng để phát hiện các dòng dữ liệu không có ý nghĩa ngôn ngữ như các chuỗi ký tự quá ngắn hoặc chứa quá ít ký tự chữ cái.

Tập dữ liệu sau khi làm sạch gồm 4.527 bản ghi và 3 thuộc tính gồm `text`, `text_clean` và `intent`. Trong đó `text` chứa nội dung phản hồi gốc, `text_clean` là dữ liệu sau khi tiền xử lý và `intent` là nhãn ý định tương ứng.

Sau quá trình tăng cường dữ liệu, tập dữ liệu mở rộng đạt 8.810 bản ghi. Điều này giúp cải thiện đáng kể tính cân bằng giữa các lớp dữ liệu và hỗ trợ quá trình huấn luyện mô hình.

2.1.1. Cấu trúc dữ liệu

File CSV có cấu trúc có cấu trúc tối giản, chỉ 2 cột:

Cột `text` bao gồm nội dung tin nhắn của khách hàng. Đây là dữ liệu đầu vào (input) mà mô hình cần học.

Cột `intent` bao gồm nhãn ý định tương ứng. Đây là “đáp án” (output) mà mô hình cần dự đoán. Có 10 giá trị phân biệt.

2.1.2. Thống kê tổng quan

Một cái nhìn nhanh về toàn bộ tập dữ liệu:

Tổng số mẫu: 4.527.

Số nhóm ý định: 10 lớp phân biệt.

Dữ liệu bị thiếu (null): 0.

Dữ liệu trùng lặp: 0.

Độ dài trung bình: 35,43 ký tự/câu $\approx$ 8,00 từ/câu.

Câu ngắn nhất: 3 ký tự (1 từ).

Câu dài nhất: 316 ký tự (72 từ).

Điểm đáng chú ý là chất lượng dữ liệu rất tốt (không có giá trị null và không có bản ghi trùng lặp), cho thấy quá trình thu thập và gán nhãn được thực hiện cẩn thận, tạo nền tảng thuận lợi cho các bước tiền xử lý và huấn luyện mô hình tiếp theo.

2.2. Các nhóm intent trong dữ liệu

Tập dữ liệu gồm 10 nhóm ý định khác nhau.

Intent	Dữ liệu gốc	Dữ liệu sau tăng cường	Mô tả dữ liệu	Ví dụ
khen_chat_luong	1.835	1.853	Các phản hồi thể hiện sự hài lòng, đánh giá tích cực về chất lượng sản phẩm như độ bền, mẫu mã, tính năng hoặc hiệu quả sử dụng.	"Sản phẩm rất tốt, chất lượng đúng như mong đợi, sẽ tiếp tục ủng hộ."
trung_tinh	1.695	1.715	Các phản hồi mang tính khách quan hoặc trung lập, không thể hiện rõ thái độ khen hay chê đối với sản phẩm hoặc dịch vụ.	"Đã nhận được hàng, đang sử dụng và"

				sẽ đánh giá thêm."
dung_voi_mo_ta	269	394	Các phản hồi xác nhận sản phẩm nhận được đúng với hình ảnh hoặc mô tả của người bán.	"Hàng giống mô tả, màu sắc và kích thước đúng như quảng cáo."
phan_nan_chat_luong	198	367	Các phản hồi phàn nàn về chất lượng sản phẩm như lỗi, hỏng hóc, kém bền hoặc không đạt kỳ vọng.	"Sản phẩm bị lỗi ngay khi sử dụng, chất lượng rất kém."
khen_giao_hang	194	367	Các phản hồi đánh giá tích cực về quá trình giao hàng như nhanh, đúng hẹn, đóng gói cẩn thận.	"Giao hàng rất nhanh, đóng gói kỹ và hàng nguyên vẹn."
gia_tri_gia	143	755	Các phản hồi liên quan đến giá cả, thể hiện sản	"Giá rất hợp lý,

			phẩm có giá hợp lý, đáng tiền hoặc giá tốt so với chất lượng.	chất lượng vượt mong đợi trong tầm giá."
de_xuat_mua	86	903	Các phản hồi thể hiện ý định giới thiệu hoặc khuyến nghị người khác mua sản phẩm, hoặc mong muốn mua lại.	"Rất đáng mua, mình sẽ giới thiệu cho bạn bè và sẽ mua thêm."
phan_nan_giao_hang	70	885	Các phản hồi phàn nàn về quá trình giao hàng như giao chậm, giao sai hoặc hàng bị hư hỏng khi vận chuyển.	"Giao hàng quá lâu, hộp bị móp và nhận sai sản phẩm."
khen_dich_vu	31	809	Các phản hồi đánh giá tích cực về chất lượng phục vụ của cửa hàng hoặc nhân viên chăm sóc khách hàng.	"Shop tư vấn rất nhiệt tình, hỗ trợ khách hàng chu đáo."
phan_nan_dich_vu	6	762	Các phản hồi không hài lòng về dịch vụ chăm sóc	"Nhấn tin rất lâu

			khách hàng, tư vấn hoặc xử lý khiếu nại.	mới trả lời, thái độ phục vụ chưa chuyên nghiệp."
--	--	--	--	---

Bảng 2.1. Các nhóm intent trong dữ liệu

Kết quả cho thấy kỹ thuật tăng cường dữ liệu đã giúp giảm đáng kể tình trạng mất cân bằng lớp.

Tổng số mẫu của bộ dữ liệu tăng từ 4.527 lên 8.810 sau quá trình tăng cường dữ liệu. Việc tăng cường chủ yếu được áp dụng cho các lớp có ít dữ liệu nhằm giảm hiện tượng mất cân bằng. Đặc biệt:

`phan_nan_dich_vu` tăng từ 6 lên 762 mẫu.

`khen_dich_vu` tăng từ 31 lên 809 mẫu.

`phan_nan_giao_hang` tăng từ 70 lên 885 mẫu.


`de_xuat_mua` tăng từ 86 lên 903 mẫu.

Trong khi đó, các lớp vốn đã có nhiều dữ liệu như `khen_chat_luong` và `trung_tinh` chỉ được bổ sung rất ít (lần lượt tăng 18 và 20 mẫu), giúp tập dữ liệu trở nên cân bằng hơn trước khi huấn luyện mô hình.

2.3. Khám phá dữ liệu EDA

2.3.1. Phân bố theo nhóm intent

Phân bố dữ liệu ban đầu cho thấy sự chênh lệch rất lớn giữa các nhóm ý định. Hai nhóm `khen_chat_luong` và `trung_tinh` chiếm phần lớn tập dữ liệu. Trong khi đó, các nhóm như `phan_nan_dich_vu` hoặc `khen_dich_vu` có số lượng rất nhỏ. Điều này có thể khiến mô hình thiên lệch về các lớp phổ biến.



Hình 2.1. Phân bố dữ liệu theo intent

Có thể nhận thấy dữ liệu không được phân bố đồng đều giữa các lớp. Hai nhóm `khen_chat_luong` và `trung_tinh` chiếm số lượng lớn nhất với khoảng 1.850 và 1.700 mẫu. Trong khi đó, các nhóm như `dung_voi_mo_ta`, `khen_giao_hang` và `phan_nhan_chat_luong` chỉ dao động trong khoảng 350-400 mẫu sau quá trình tăng cường dữ liệu.

Sự chênh lệch về số lượng mẫu giữa các lớp có thể làm mô hình học thiên lệch về các lớp chiếm ưu thế. Vì vậy, trong quá trình xây dựng hệ thống, đề tài đã áp dụng kỹ thuật Data Augmentation nhằm cân bằng dữ liệu trước khi huấn luyện mô hình.

2.3.2. Phân tích độ dài câu chat

Đặc trưng độ dài văn bản được tính theo số ký tự của tập dữ liệu có các thống kê như sau:

Chỉ số thống kê	Giá trị
Tổng số mẫu	8810
Trung bình (mean)	42.21 ký tự

Độ lệch chuẩn (std)	32.72 ký tự
Ngắn nhất (min)	3 ký tự
Phân vị 25% (Q1)	20 ký tự
Trung vị (median, Q2)	32 ký tự
Phân vị 75% (Q3)	53 ký tự
Dài nhất (max)	316 ký tự


Bảng 2.2. Các chỉ số cơ bản của tập dữ liệu

Độ dài trung bình câu chat là 42.21 ký tự, rất ngắn so với các bài toán NLP thông thường (bài báo, tài liệu...). Điều này phản ánh tính chất đặc trưng của bình luận: ngắn gọn, súc tích, thường thiếu ngữ cảnh đầy đủ. Phân vị 75% là 53 ký tự cho thấy phần lớn tin nhắn đều rất ngắn. Tuy nhiên vẫn có một số câu dài tới 316 ký tự - thường là các câu khiêu nại hoặc mô tả vấn đề chi tiết.

2.3.3. Phân tích biểu đồ phân phối (histogram)

Biểu đồ phân phối (histogram) của độ dài câu cho thấy phân bố lệch trái (left-skewed), phần lớn câu có độ dài dưới 50 ký tự, với đỉnh tập trung ở khoảng 20-30 ký tự.


Kết quả này cũng hỗ trợ cho việc lựa chọn tham số trong quá trình huấn luyện mô hình PhoBERT. Với phần lớn câu có độ dài ngắn, việc sử dụng `max_length = 32` token giúp mô hình vẫn giữ được hầu hết nội dung quan trọng của câu, đồng thời giảm lượng padding không cần thiết và tối ưu thời gian xử lý dữ liệu.



Hình 2.2. Biểu đồ phân bố dữ liệu theo intent

2.3.4. Phân tích Word Cloud

Word Cloud cho thấy các từ xuất hiện nhiều nhất trong tập dữ liệu bao gồm các từ liên quan đến chất lượng sản phẩm như "đẹp", "tốt", "ổn", "xịn", "chất lượng", "giao hàng", "nhanh", "giá", "dịch vụ". Những từ khóa này phản ánh đúng nội dung và mục tiêu phân loại của bài toán.



Hình 2.3. Word Cloud của tập dữ liệu

2.3.5. Phân tích đặc điểm ngôn ngữ

Dữ liệu chứa nhiều từ ngữ mang tính khẩu ngữ và đặc trưng của môi trường đánh giá trực tuyến. Người dùng thường sử dụng từ viết tắt như "ok", "oke", "shop", "sp", đồng thời xuất hiện nhiều biến thể chính tả của cùng một từ. Đây là lý do đề tài cần thực hiện bước chuẩn hóa văn bản trước khi huấn luyện mô hình.

2.4. Nhận xét về dữ liệu

Sau khi thực hiện phân tích EDA toàn diện, có thể đưa ra một số nhận xét tổng hợp về chất lượng và đặc điểm của bộ dữ liệu:

2.4.1. Về điểm mạnh

Tập dữ liệu có quy mô phù hợp với 13206 mẫu là đủ lớn cho cả Machine Learning truyền thống và fine-tuning mô hình BERT, tạo điều kiện so sánh công bằng giữa hai hướng tiếp cận.

Với độ đa dạng cao, tập dữ liệu bao phủ 10 nhóm intent với các tình huống thực tế phong phú, từ giao dịch mua bán đến xử lý khiếu nại và giao tiếp xã hội.

Dữ liệu được lấy ý tưởng và tạo ra từ hội thoại thực tế, phản ánh đúng ngôn ngữ và hành vi của người dùng Việt Nam trong môi trường thương mại điện tử.

2.4.2. Về hạn chế và thách thức

Mất cân bằng nhãn khiến chênh lệch gần 5 lần giữa nhóm đông nhất và ít nhất có thể ảnh hưởng đến khả năng nhận diện các lớp thiểu số như `phan_nhan_chat_luong` hoặc `khen_giao_hang`.

Câu ngắn và thiếu ngữ cảnh cũng là hạn chế với độ dài trung bình chỉ 42 ký tự, nhiều câu rất cụt, đòi hỏi mô hình phải học được đặc trưng phân biệt từ rất ít thông tin văn bản.

Ngôn ngữ không chuẩn như từ viết tắt, lỗi chính tả đòi hỏi bước tiền xử lý kỹ lưỡng và không thể bỏ qua trong pipeline.

CHƯƠNG 3: XÂY DỰNG BÀI TOÁN

3.1. Xác định bài toán

Bài toán được xây dựng trong đề tài là bài toán phân loại văn bản đa lớp nhằm nhận diện ý định của khách hàng thông qua các đánh giá sản phẩm trong môi trường thương mại điện tử. Đầu vào của hệ thống là các câu đánh giá bằng tiếng Việt, trong khi đầu ra là nhãn ý định tương ứng được xác định từ nội dung đánh giá.

Quá trình xây dựng bài toán được triển khai qua ba notebook chính. File `XuLyData.ipynb` chịu trách nhiệm làm sạch dữ liệu và gán nhãn ý định. File `AugmentData.ipynb` thực hiện tăng cường dữ liệu nhằm giải quyết hiện tượng mất cân bằng lớp. File `BaoCao_final.ipynb` thực hiện phân tích dữ liệu khám phá, xây dựng đặc trưng, huấn luyện mô hình và đánh giá kết quả.

Sau quá trình xử lý dữ liệu, hệ thống tiến hành phân loại các đánh giá vào các nhóm ý định như khen chất lượng sản phẩm, phàn nàn chất lượng, khen giao hàng, phàn nàn giao hàng, khen dịch vụ, phàn nàn dịch vụ, đánh giá giá trị sản phẩm, đề xuất mua hàng, đúng với mô tả và nhóm trung tính.


3.2. Kiến trúc tổng thể của hệ thống

Quy trình xử lý dữ liệu của hệ thống được xây dựng thành ba giai đoạn chính.

Giai đoạn đầu tiên được thực hiện trong file `XuLyData.ipynb`. Dữ liệu đánh giá ban đầu được nạp vào hệ thống, tiến hành làm sạch văn bản, loại bỏ dữ liệu nhiễu và gán nhãn intent bằng tập luật từ khóa. Kết quả sau xử lý được lưu thành tập tin `data_cleaned_with_intent.csv`.

Giai đoạn thứ hai được thực hiện trong file `AugmentData.ipynb`. Dữ liệu đã gán nhãn được tăng cường bằng hai phương pháp gồm Back Translation và Easy Data Augmentation nhằm tạo thêm các câu mới cho các lớp dữ liệu có số lượng thấp. Kết quả được lưu thành tập tin `data_augmented.csv`.

Giai đoạn cuối cùng được thực hiện trong file `BaoCao_final.ipynb`. Tập dữ liệu tăng cường được sử dụng để phân tích dữ liệu, chuyển đổi văn bản thành vector TF-IDF hoặc token PhoBERT, huấn luyện các mô hình học máy truyền thống và mô hình PhoBERT, sau đó đánh giá hiệu năng bằng nhiều chỉ số khác nhau.



Hình 3.1. Pipeline tổng quát của hệ thống

3.3. Tiền xử lý dữ liệu

Toàn bộ quá trình tiền xử lý dữ liệu được thực hiện trong file `XuLyData.ipynb`.

Sau khi dữ liệu được nạp vào DataFrame `df_raw`, hệ thống tiến hành chuẩn hóa dữ liệu thông qua hàm `clean_text()`.

Trong hàm này, khoảng trắng liên tiếp được chuẩn hóa bằng lệnh:

```
text = re.sub(r'\s+', ' ',
text).strip()
```

Tiếp theo, các ký tự không thuộc bảng chữ cái tiếng Việt hoặc các ký tự đặc biệt không cần thiết được loại bỏ bằng lệnh:

```
text = re.sub(
    r'[^\\w\\s\\u00C0-\\u024F\\u1E00-\\u1EFF\\u0300-\\u036F.,!?!]',
    '',
    text
)
```

Sau đó hệ thống tiến hành tách từ và chỉ giữ lại các token có chứa ít nhất một ký tự chữ cái:

```

meaningful = [
    t for t in tokens
    if len(
        re.sub(
            r'^a-zA-Z\u00C0-\u024F\u1E00-\u1EFF',
            '',
            t
        )
    ) >= 1
]

```

Để loại bỏ các dữ liệu không có ý nghĩa, notebook sử dụng hàm `is_noise()`.

Một dòng dữ liệu được coi là nhiễu nếu độ dài nhỏ hơn 3 ký tự:

```

if not isinstance(text, str) or len(text.strip()) < 3:
    return True

```

Hoặc tỷ lệ ký tự chữ cái quá thấp:

```

if len(meaningful_chars) / len(stripped) < 0.3:
    return True

```

Hoặc tỷ lệ từ đơn ký tự vượt quá 70% số từ trong câu:

```

if single_char_ratio > 0.7 and len(tokens) >= 4:
    return True

```

Sau khi hoàn thành bước làm sạch dữ liệu, notebook tạo ra hai cột mới gồm `text_clean` và `is_noise`. Những dòng dữ liệu được xác định là nhiễu sẽ bị loại bỏ khỏi tập dữ liệu huấn luyện.

3.4. Gán nhãn ý định

Quá trình gán nhãn được thực hiện trong file `XuLyData.ipynb` thông qua biến `INTENT_RULES`.

Mỗi intent được xây dựng dựa trên một tập hợp từ khóa đặc trưng. Ví dụ, nhóm `khen_chat_luong` được xác định từ các từ khóa như:

```
['chất_lượng', 'chất lượng',
'tốt', 'tuyệt', 'ổn', 'oke',
'ok', 'chắc', 'bền', 'đẹp',
'xinh', 'xịn', 'ngon',
'chuẩn', 'mềm', 'nhẹ', 'êm']
```

Nhóm `phan_nhan_chat_luong` được xây dựng từ các từ khóa:

```
['kém', 'tệ', 'lỗi',
'hỏng', 'xấu',
'không đúng',
'thất_vọng',
'không ổn',
'không như hình']
```

Tương tự, các nhóm liên quan đến giao hàng và dịch vụ được xác định bằng các tập từ khóa riêng biệt.

Sau khi quét toàn bộ nội dung của cột `text_clean`, hệ thống gán nhãn intent phù hợp cho từng dòng dữ liệu và lưu kết quả cuối cùng vào file `data_cleaned_with_intent.csv`.

3.5. Tăng cường dữ liệu

Toàn bộ quá trình tăng cường dữ liệu được thực hiện trong file `AugmentData.ipynb`.

Notebook thiết lập các tham số chính như sau:

```
TARGET_ROWS = 12000
MAX_PER_INTENT = 1500
SLEEP_BACKTRANS = 1.2
RATIO_BACKTRANS = 0.5
RATIO_EDA = 0.5
```

Trong đó `TARGET_ROWS = 12000` là tổng số dòng dữ liệu mong muốn sau khi tăng cường.

`MAX_PER_INTENT = 1500` quy định số lượng mẫu tối đa được sinh thêm cho mỗi nhóm intent.

`RATIO_BACKTRANS = 0.5` và `RATIO_EDA = 0.5` cho biết dữ liệu sinh mới được chia đều giữa hai phương pháp Back Translation và Easy Data Augmentation.

Notebook sử dụng hàm `compute_needed()` để xác định số lượng mẫu cần bổ sung cho từng lớp dựa trên tần suất xuất hiện hiện tại của lớp đó.

Các lớp có ít dữ liệu sẽ được ưu tiên sinh thêm nhiều mẫu hơn nhằm giảm hiện tượng mất cân bằng.

3.6. Thực hiện Easy Data Augmentation (EDA)

Trong file `AugmentData.ipynb`, phương pháp EDA được triển khai thông qua ba hàm chính.

Hàm `synonym_replace()` thực hiện thay thế từ bằng từ đồng nghĩa dựa trên từ điển `SYNONYMS`.

Ví dụ từ "đẹp" có thể được thay thế bằng:

```
['xinh', 'xịn', 'oke',  
'ngon', 'tuyệt',  
'chuẩn', 'ung']
```

Hàm `random_swap()` thực hiện hoán đổi vị trí của hai từ ngẫu nhiên trong câu.

Hàm `random_delete()` thực hiện xóa từ ngẫu nhiên với xác suất $p = 0.15$.

Những phương pháp này tạo ra các câu mới có cấu trúc khác nhau nhưng vẫn giữ nguyên ý nghĩa của câu gốc.

3.7. Thực hiện Back Translation

Back Translation được triển khai bằng thư viện `deep_translator`.

Quá trình dịch được thực hiện thông qua hàm `back_translate()`.

Trong hàm này, câu tiếng Việt được dịch sang tiếng Anh:

```
GoogleTranslator(  
    source='vi',  
    target='en'  
)
```

Sau đó tiếp tục dịch ngược trở lại tiếng Việt:

```
GoogleTranslator(  
    source='en',  
    target='vi'  
)
```

Thời gian chờ giữa hai lần gọi API được thiết lập `sleep = 1.2` để hạn chế nguy cơ bị chặn bởi Google Translate.

Những câu sau khi dịch ngược có nội dung khác biệt nhưng vẫn giữ nguyên ý nghĩa sẽ được đưa vào tập dữ liệu mới.

3.8. Chia tập dữ liệu huấn luyện và kiểm tra

Sau khi hoàn thành bước tăng cường dữ liệu, notebook `BaoCao_final.ipynb` tiến hành chia dữ liệu bằng hàm `train_test_split()` với các tham số:

```
test_size = 0.2
stratify = y
random_state = 42
```

Điều này có nghĩa là 80% dữ liệu được sử dụng để huấn luyện và 20% dữ liệu được sử dụng để kiểm tra.

Tham số `stratify=y` giúp duy trì tỷ lệ phân bố các lớp giống nhau giữa tập huấn luyện và tập kiểm tra.

3.9. Vector hóa dữ liệu bằng TF-IDF

Đối với các mô hình học máy truyền thống, văn bản được chuyển thành vector số bằng bộ biến đổi TF-IDF.

Trong notebook, bộ vector hóa được khởi tạo như sau:

```
tfidf = TfidfVectorizer(
    max_features = 5000,
    ngram_range = (1,2)
)
```

Tham số `max_features = 5000` cho phép giữ lại tối đa 5000 đặc trưng quan trọng nhất.

Tham số `ngram_range = (1,2)` cho phép sử dụng đồng thời unigram và bigram.

Sau khi huấn luyện bộ TF-IDF trên tập huấn luyện `X_train_tfidf = tfidf.fit_transform(X_train)` dữ liệu kiểm tra được biến đổi bằng `X_test_tfidf = tfidf.transform(X_test)`.

3.10. Huấn luyện các mô hình học máy truyền thống

Ba mô hình học máy được huấn luyện trong notebook gồm Multinomial Naive Bayes, Logistic Regression và LinearSVC.

Mô hình Naive Bayes được xây dựng bằng:

```
nb = MultinomialNB()
```

Mô hình Logistic Regression được xây dựng bằng:

```
lr = LogisticRegression(
    max_iter=1000
)
```

Mô hình SVM được xây dựng bằng:

```
svm = LinearSVC()
```

Sau khi huấn luyện, các mô hình được sử dụng để dự đoán trên tập kiểm tra và đánh giá bằng Accuracy, Precision, Recall và F1-score.

3.11. Đánh giá bằng Cross Validation

Để đánh giá độ ổn định của mô hình, notebook sử dụng kỹ thuật Cross Validation.

Việc đánh giá được thực hiện bằng lệnh:

```
cross_val_score(
    clf,
    X_train_tfidf,
    y_train,
    cv=5,
    scoring="f1_weighted"
)
```

Trong đó số fold được thiết lập `cv = 5` và chỉ số đánh giá là `f1_weighted`.

Kết quả cuối cùng được tính bằng giá trị trung bình và độ lệch chuẩn của năm lần đánh giá.

3.12. Triển khai mô hình PhoBERT

PhoBERT được triển khai trong phần cuối của notebook `BaoCao_final.ipynb`.

Tokenizer được tải bằng:

```
AutoTokenizer.from_pretrained(
    "vinai/phobert-base"
)
```

Văn bản được token hóa với các tham số:

```
truncation = True
padding = "max_length"
max_length = 64
```

Mô hình phân loại được khởi tạo bằng:

```
AutoModelForSequenceClassification.from_pretrained(
    "vinai/phobert-base",
    num_labels=num_labels
)
```

Các tham số huấn luyện được thiết lập:

```
learning_rate = 2e-5
per_device_train_batch_size = 16
per_device_eval_batch_size = 16
num_train_epochs = 5
weight_decay = 0.01
warmup_ratio = 0.1
logging_steps = 50
save_total_limit = 2
```

Chiến lược đánh giá và lưu mô hình được thực hiện theo từng epoch:

```
eval_strategy = "epoch"
save_strategy = "epoch"
```

Mô hình tốt nhất được tự động lưu lại thông qua:

```
load_best_model_at_end = True
metric_for_best_model = "f1"
```

Sau khi hoàn thành huấn luyện bằng lớp `Trainer`, mô hình sẽ được đánh giá trên tập kiểm tra và các kết quả sẽ được đưa vào bảng so sánh với các mô hình học máy truyền thống.

3.13. Kết quả thực nghiệm

Kết quả thực nghiệm cho thấy việc tăng cường dữ liệu đã cải thiện đáng kể hiệu năng của các mô hình. Các lớp dữ liệu trước đây có số lượng rất ít đã được học tốt hơn sau khi cân bằng dữ liệu.

Các mô hình học máy truyền thống đạt kết quả khả quan khi sử dụng TF-IDF kết hợp với dữ liệu tăng cường. Tuy nhiên, các mô hình này vẫn gặp khó khăn trong việc xử lý các câu có ngữ nghĩa phức tạp hoặc chứa nhiều biến thể ngôn ngữ.

PhoBERT cho kết quả vượt trội nhờ khả năng khai thác ngữ cảnh sâu và hiểu được đặc điểm của tiếng Việt. Mô hình có khả năng nhận diện chính xác hơn đối với các lớp dữ liệu dễ gây nhầm lẫn như `khen_chat_luong` và `dung_voi_mo_ta` hoặc giữa `phan_nan_chat_luong` và `phan_nan_dich_vu`.

Kết quả chi tiết về Accuracy, Precision, Recall và F1-score được trình bày trong phần bảng kết quả và biểu đồ đánh giá của đề tài.

	Model	Accuracy	Precision	Recall	F1
0	Naive Bayes	0.847900	0.864020	0.847900	0.842530
1	Logistic Regression	0.910329	0.914103	0.910329	0.909611
2	SVM	0.931896	0.933048	0.931896	0.931692
3	PhoBERT	0.950624	0.951692	0.950624	0.950674

Bảng 3.1. Tổng hợp các chỉ số của các mô hình

3.14. So sánh ưu và nhược điểm của các mô hình

Naive Bayes có ưu điểm là tốc độ huấn luyện nhanh, dễ triển khai và tiêu tốn ít tài nguyên tính toán. Tuy nhiên, giả định độc lập giữa các đặc trưng khiến mô hình khó khai thác được các mối quan hệ ngữ nghĩa phức tạp.

Logistic Regression cho hiệu năng ổn định hơn và có khả năng học ranh giới phân loại tốt. Tuy nhiên, mô hình vẫn phụ thuộc nhiều vào chất lượng vector TF-IDF.

Support Vector Machine đạt kết quả tốt trên dữ liệu có số chiều lớn và thường vượt trội hơn Naive Bayes. Nhược điểm của mô hình là thời gian huấn luyện tăng lên khi kích thước dữ liệu mở rộng.

PhoBERT là mô hình có khả năng biểu diễn ngữ nghĩa mạnh nhất trong nghiên cứu. Nhờ được huấn luyện trước trên lượng lớn dữ liệu tiếng Việt, PhoBERT đạt độ chính xác cao và khả năng tổng quát hóa tốt. Tuy nhiên, mô hình yêu cầu tài nguyên tính toán lớn hơn, thời gian huấn luyện dài hơn và quá trình triển khai thực tế cũng phức tạp hơn so với các phương pháp truyền thống.

Nhìn chung, PhoBERT là lựa chọn phù hợp nhất cho bài toán nhận diện ý định tiếng Việt trong thương mại điện tử khi mục tiêu là tối đa hóa độ chính xác, trong khi các mô hình TF-IDF kết hợp học máy truyền thống là giải pháp hiệu quả khi ưu tiên tốc độ và chi phí triển khai.

Mô hình	Ưu điểm	Nhược điểm
Naive Bayes	Huấn luyện nhanh, ít tài nguyên.	Giả định độc lập đặc trưng nên khó nắm bắt ngữ nghĩa phức tạp.
Logistic Regression	Dễ triển khai, kết quả ổn định.	Khả năng biểu diễn quan hệ ngữ cảnh còn hạn chế.
SVM	Hiệu quả cao trên dữ liệu TF-IDF.	Thời gian huấn luyện có thể tăng khi dữ liệu lớn.
PhoBERT	Hiểu ngữ cảnh tiếng Việt tốt, hiệu năng cao nhất.	Yêu cầu tài nguyên tính toán lớn và thời gian huấn luyện dài hơn.

Bảng 3.2. Ưu nhược điểm của các mô hình

CHƯƠNG 4: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

4.1. Kết luận

Trong phạm vi nghiên cứu của đề tài, một hệ thống nhận diện ý định khách hàng bằng tiếng Việt trong lĩnh vực thương mại điện tử đã được xây dựng và đánh giá thông qua nhiều phương pháp khác nhau. Toàn bộ quy trình từ xử lý dữ liệu, tăng cường dữ liệu, xây dựng đặc trưng, huấn luyện mô hình đến đánh giá kết quả đều được triển khai và kiểm chứng trên tập dữ liệu thực tế.

Ở giai đoạn xử lý dữ liệu, notebook `XuLyData.ipynb` đã thực hiện thành công việc làm sạch văn bản, loại bỏ dữ liệu nhiễu và xây dựng cơ chế gán nhãn intent dựa trên tập luật từ khóa. Quá trình này giúp chuyển đổi dữ liệu thô thành tập dữ liệu có cấu trúc và có thể sử dụng cho các bước huấn luyện tiếp theo. Kết quả đầu ra được lưu trong tập tin `data_cleaned_with_intent.csv`, tạo nền tảng cho toàn bộ quá trình nghiên cứu.

Đối với bài toán mất cân bằng dữ liệu, notebook `AugmentData.ipynb` đã áp dụng hai kỹ thuật tăng cường dữ liệu gồm Easy Data Augmentation và Back Translation. Việc kết hợp hai phương pháp này giúp gia tăng đáng kể số lượng mẫu của các lớp có ít dữ liệu, đồng thời tạo ra nhiều cách diễn đạt khác nhau cho cùng một ý định. Sau quá trình tăng cường, tập dữ liệu thu được có độ cân bằng cao hơn, giúp cải thiện khả năng học của các mô hình phân loại.

Trong giai đoạn xây dựng mô hình, notebook `BaoCao_final.ipynb` đã triển khai đồng thời hai hướng tiếp cận. Hướng tiếp cận thứ nhất sử dụng các mô hình học máy truyền thống gồm Multinomial Naive Bayes, Logistic Regression và LinearSVC kết hợp với phương pháp TF-IDF để biểu diễn văn bản. Hướng tiếp cận thứ hai sử dụng mô hình ngôn ngữ tiền huấn luyện PhoBERT nhằm khai thác khả năng biểu diễn ngữ nghĩa chuyên sâu cho tiếng Việt.

Kết quả thực nghiệm cho thấy các mô hình học máy truyền thống đạt hiệu quả tương đối tốt trên tập dữ liệu đã được xử lý và tăng cường. Đặc biệt, Logistic Regression và LinearSVC thể hiện khả năng phân loại ổn định khi kết hợp với đặc trưng TF-IDF. Tuy nhiên, các mô hình này vẫn gặp hạn chế trong việc nắm bắt ngữ cảnh và quan hệ ngữ nghĩa giữa các từ.

Trong khi đó, PhoBERT cho thấy ưu thế rõ rệt nhờ khả năng tận dụng tri thức ngôn ngữ đã được học từ quá trình tiền huấn luyện trên kho dữ liệu tiếng Việt quy mô lớn. Mô hình không chỉ cải thiện độ chính xác tổng thể mà còn nâng cao khả năng phân biệt giữa các nhóm ý định có nội dung gần giống nhau. Điều này cho thấy các mô hình Transformer hiện đại là hướng tiếp cận phù hợp đối với các bài toán phân loại văn bản tiếng Việt trong thực tế.

Thông qua quá trình nghiên cứu và thực nghiệm, đề tài đã hoàn thành mục tiêu đề ra là xây dựng được một hệ thống nhận diện ý định khách hàng dựa trên dữ liệu phản hồi bằng tiếng Việt, đồng thời đánh giá và so sánh hiệu quả của nhiều phương pháp khác nhau trên cùng một tập dữ liệu.

4.2. Những đóng góp của đề tài

Đề tài đã xây dựng được một quy trình hoàn chỉnh cho bài toán nhận diện ý định tiếng Việt, bao gồm các bước tiền xử lý dữ liệu, gán nhãn, tăng cường dữ liệu, huấn luyện mô hình và đánh giá kết quả. Quy trình này có thể được tái sử dụng cho các nghiên cứu hoặc ứng dụng tương tự trong lĩnh vực thương mại điện tử.

Đề tài đã xây dựng được tập dữ liệu có nhãn từ dữ liệu đánh giá sản phẩm ban đầu thông qua hệ thống luật từ khóa. Việc xây dựng tập dữ liệu này giúp tạo ra nguồn dữ liệu phục vụ cho các nghiên cứu NLP tiếng Việt trong tương lai.

Đề tài đã triển khai thành công các kỹ thuật tăng cường dữ liệu bằng EDA và Back Translation nhằm giải quyết vấn đề mất cân bằng lớp. Đây là một bước quan trọng giúp cải thiện chất lượng dữ liệu huấn luyện và nâng cao hiệu năng mô hình.

Đề tài đã thực hiện đánh giá đồng thời các mô hình học máy truyền thống và mô hình Transformer hiện đại trên cùng một tập dữ liệu, từ đó cung cấp cơ sở thực nghiệm để lựa chọn phương pháp phù hợp cho bài toán nhận diện ý định tiếng Việt.

Đề tài cũng chứng minh được tính hiệu quả của PhoBERT đối với các tác vụ phân loại văn bản trong môi trường thương mại điện tử, góp phần khẳng định vai trò của các mô hình ngôn ngữ tiền huấn luyện trong xử lý ngôn ngữ tự nhiên tiếng Việt.

4.3. Hạn chế của đề tài

Mặc dù đạt được nhiều kết quả tích cực trong quá trình nghiên cứu và triển khai hệ thống nhận diện intent tiếng Việt, đề tài vẫn còn tồn tại một số hạn chế nhất định liên

Mặc dù đã đạt được các mục tiêu nghiên cứu đề ra, đề tài vẫn còn một số hạn chế nhất định.

Thứ nhất, quá trình gán nhãn dữ liệu được thực hiện dựa trên tập luật từ khóa trong notebook `XuLyData.ipynb`. Phương pháp này giúp tiết kiệm thời gian gán nhãn thủ công nhưng có thể dẫn đến một số trường hợp gán nhãn chưa hoàn toàn chính xác, đặc biệt đối với các câu chứa nhiều ý nghĩa hoặc các cách diễn đạt phức tạp.

Thứ hai, mặc dù đã áp dụng các kỹ thuật tăng cường dữ liệu, chất lượng của các câu được sinh ra vẫn phụ thuộc vào từ điển đồng nghĩa và kết quả dịch ngược. Một số mẫu dữ liệu mới có thể chưa hoàn toàn tự nhiên như dữ liệu do con người tạo ra.

Thứ ba, phạm vi nghiên cứu chỉ tập trung vào dữ liệu văn bản tiếng Việt trong lĩnh vực thương mại điện tử. Do đó, khả năng tổng quát hóa của mô hình sang các lĩnh vực khác như tài chính, giáo dục hoặc chăm sóc sức khỏe chưa được kiểm chứng.

Thứ tư, nghiên cứu mới chỉ triển khai PhoBERT-base mà chưa đánh giá thêm các mô hình ngôn ngữ hiện đại khác như BERT multilingual, viBERT, viDeBERTa hoặc các mô hình ngôn ngữ lớn (Large Language Models).

Thứ năm, hệ thống hiện tại mới dừng ở mức nghiên cứu và đánh giá mô hình. Chưa có bước triển khai thành một hệ thống trực tuyến hoặc tích hợp vào môi trường sản xuất thực tế.

4.4. Hướng phát triển

Trong tương lai, đề tài có thể được mở rộng theo nhiều hướng khác nhau nhằm nâng cao hiệu quả và khả năng ứng dụng thực tế.

Hướng phát triển đầu tiên là mở rộng quy mô dữ liệu huấn luyện. Việc thu thập thêm dữ liệu từ các sàn thương mại điện tử và các nền tảng đánh giá sản phẩm khác sẽ giúp mô hình học được nhiều mẫu ngôn ngữ đa dạng hơn và nâng cao khả năng tổng quát hóa.

Hướng phát triển thứ hai là cải thiện chất lượng gán nhãn dữ liệu. Thay vì sử dụng hoàn toàn tập luật từ khóa, có thể kết hợp giữa gán nhãn tự động và kiểm duyệt thủ công nhằm tăng độ chính xác của tập dữ liệu huấn luyện.

Hướng phát triển thứ ba là nghiên cứu thêm các kỹ thuật tăng cường dữ liệu hiện đại dựa trên mô hình ngôn ngữ lớn. Các mô hình sinh văn bản có thể tạo ra các câu mới tự nhiên hơn so với các phương pháp EDA truyền thống.

Hướng phát triển thứ tư là mở rộng nghiên cứu sang các mô hình Transformer tiên tiến hơn như PhoBERT-large, viDeBERTa hoặc các mô hình ngôn ngữ lớn được tối ưu cho tiếng Việt. Việc so sánh nhiều mô hình khác nhau sẽ giúp lựa chọn được giải pháp tối ưu cho từng yêu cầu cụ thể.

Hướng phát triển thứ năm là kết hợp bài toán nhận diện ý định với các tác vụ NLP khác như phân tích cảm xúc, trích xuất thực thể hoặc tóm tắt nội dung phản hồi. Điều này sẽ giúp xây dựng một hệ thống phân tích khách hàng toàn diện hơn.

Cuối cùng, hệ thống có thể được triển khai dưới dạng ứng dụng web hoặc API để hỗ trợ doanh nghiệp tự động phân loại phản hồi khách hàng theo thời gian thực. Khi đó, kết quả nhận diện ý định không chỉ phục vụ nghiên cứu mà còn có thể được ứng dụng trực tiếp trong các hoạt động chăm sóc khách hàng và quản lý chất lượng dịch vụ của doanh nghiệp.

CHƯƠNG 5: TÀI LIỆU THAM KHẢO

- [1] VNPT AI. (n.d.). *Intent Recognition là gì? Ứng dụng rộng rãi của Intent Recognition trong thực tế*. <https://vnptai.io/vi/blog/detail/intent-recognition>
- [2] VNPT AI. (n.d.). *Xử lý ngôn ngữ tự nhiên là gì? Lợi ích và ứng dụng nổi bật của NLP*. <https://vnptai.io/vi/blog/detail/xu-ly-ngon-ngu-tu-nhien-la-gi>
- [3] Zendesk. (n.d.). *Chatbot NLP là gì và chúng hoạt động như thế nào?*. <https://www.zendesk.com/blog/ai/chatbots/nlp-chatbot/>
- [4] Nguyen, D. Q., & Nguyen, A. T. (2020). *PhoBERT: Pre-trained language models for Vietnamese*. Proceedings of the Findings of the Association for Computational Linguistics: EMNLP 2020, 1037–1042.
- [5] Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2019). *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*. Proceedings of NAACL-HLT 2019, 4171–4186.
- [6] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). *Attention Is All You Need*. Advances in Neural Information Processing Systems (NeurIPS 2017).
- [7] HuggingFace. (n.d.). *Transformers Documentation*. Available at: <https://huggingface.co/docs/transformers/index>
- [8] Scikit-learn. (n.d.). *Scikit-learn Machine Learning Documentation*. Available at: <https://scikit-learn.org/stable/documentation.html>
- [9] Jurafsky, D., & Martin, J. H. (2023). *Speech and Language Processing* (3rd Edition Draft). Stanford University.
- [10] Brownlee, J. (2020). *Machine Learning Mastery With Python*. Machine Learning Mastery.
- [11] Zhang, C., & Wang, H. (2016). *A Joint Model of Intent Determination and Slot Filling for Spoken Language Understanding*. Proceedings of IJCAI 2016.
- [12] Young, T., Hazarika, D., Poria, S., & Cambria, E. (2018). *Recent Trends in Deep Learning Based Natural Language Processing*. IEEE Computational Intelligence Magazine, 13(3), 55–75.

PHỤ LỤC

Phụ lục A. Link dữ liệu gốc:

https://github.com/nhtlongcs/shopee-reviews-sentiment-analysis/blob/master/data/automated/v3_sentences.txt

Phụ lục B. Link Dataset:

https://drive.google.com/drive/folders/1qc2NZGYX9MYiW3xhyBQZqGkFpbiI2md1?usp=drive_link

Phụ lục C. Link Code:

<https://drive.google.com/drive/u/4/folders/1RToyrqIY1dSVtNRT2YDoGskqywAhrybU>

CỘNG HÒA XÃ HỘI CHỦ NGHĨA VIỆT NAM

Độc lập - Tự do - Hạnh phúc

---oOo---

BIÊN BẢN HỌP NHÓM 16

(V/v Phân công công việc /Đánh giá hoàn thành công việc)

1. Thời gian, địa điểm, thành phần tham dự:

1.1. Thời gian: 20 giờ ngày 06/05/2026

1.2. Địa điểm: Google Meet

1.3. Thành phần tham dự:

+ Chủ trì: Trần Tuấn Kiệt

+ Tham dự: 3

+ Vắng: 0

2. Nội dung cuộc họp:

2.1. Tên đề tài:

Đề tài: Nhận diện ý định người dùng trong chat mua hàng.

2.2. Công việc các thành viên như sau:

MSSV	Họ tên thành viên	Tỉ lệ đóng góp	Công việc được phân công	Công việc cụ thể
2044230089	Trần Tuấn Kiệt	33.3%	Kiểm duyệt nội dung tổng thể, rà soát logic chiến lược và chỉnh sửa học thuật, Mô hình PhoBERT và trực quan kết quả	Tokenizer PhoBERT, Dataset HuggingFace, TrainingArguments, Trainer, fine-tuning

				PhoBERT, evaluate model, predict intent, confusion matrix, biểu đồ so sánh mô hình, PowerPoint trình bày
2044230065	Võ Thanh Hiền	33.3%	Chỉnh sửa Word, Tiền xử lý và phân tích dữ liệu	Làm sạch dữ liệu text, xử lý từ viết tắt, regex, Label Encoding, kiểm tra dữ liệu thiếu, thống kê dữ liệu, biểu đồ countplot, histogram, WordCloud
2044230151	Nguyễn Thị Thanh Nhã	33.3%	Làm PowerPoint, Xây dựng mô hình Machine Learning truyền thống	Cài thư viện, import package, đọc dữ liệu CSV, kiểm tra dữ liệu, TF-IDF Vectorizer, train/test split, huấn luyện

				Naive Bayes, Logistic Regression, Linear SVM
--	--	--	--	---

2.3. Ý kiến của các thành viên:

Tất cả các thành viên thống nhất ý kiến.

2.4. Kết luận cuộc họp:

Thống nhất đánh giá mức độ hoàn thành công việc được phân công của từng thành viên:

Hoàn thành tốt (100%); hoàn thành (90%); Không hoàn thành (0%)

(Đây là căn cứ đánh giá mức độ hoàn thành công việc của từng thành viên)

Cuộc họp đi đến thống nhất và kết thúc lúc 22 giờ 30 phút cùng ngày.

Thư ký

(Ký và ghi rõ họ tên)

Chủ trì

(Ký và ghi rõ họ tên)